

隐马尔可夫模型 (Hidden Markov Model, HMM)

SYSU-SPF 机器学习不开修班讲义

付昱宇 中山大学数学学院 88 逸仙学院

本讲义分为以下几个部分:

①- 例子引入

②- HMM 定义与经典问题

③- Forward 算法: $P(O | \lambda)$

④- Viterbi 算法: $I^* = \arg\max_I P(I | O, \lambda)$

⑤- Baum-welch 算法: $\lambda^* = \arg\max_{\lambda} P(O | \lambda)$

①- 例子引入

每天

I

考虑一个人, 他有两种状态 (state), 状态集合 $I = \{\text{开心}, \text{不开心}\}$.

在每一个状态下, 他会做出一些可被人们察觉的行为 (observation), 行为集 $O = \{\text{睡觉}, \text{玩}, \text{工作}\}$. 现在开始, 我们每天都观测这个人的行为, 假设观测了 100 天, 那么我们会得到这个人 100 天的行为序列, 但是这 100 天此人每天的状态是不可直接测得的.

HMM 便是对这个例子的数学建模, 我们希望通过行为序列 $(O_1, O_2, \dots, O_{100})$ 的研究, 找出可能的隐藏状态序列.

注: 状态序列不可测, 故 Hidden


进一步假设:

一 马尔可夫性假设. 即 $\forall t \in \mathbb{N}^+, t \geq 2$, 第 t 天的状态只与第 $(t-1)$ 天状态有关, i.e.

$$\begin{aligned} & P(i_t = i \mid i_{t-1} = j, i_{t-2} = \dots, \dots, i_1 = \dots) \\ &= P(i_t = i \mid i_{t-1} = j) = a_{ji} \quad (\text{一个不依赖 } t \text{ 的常数}). \end{aligned}$$

一 发射 (emission) 无关假设. 即 $\forall t \in \mathbb{N}^+$, 第 t 天的行为只与第 t 天的状态有关, i.e.

$$\begin{aligned} & P(O_t = o \mid i_1, O_1, i_2, O_2, \dots, i_t, O_t, i_{t+1}, O_{t+1}, \dots, i_T, O_T) \\ &= P(O_t = o \mid i_t) = b_{jo} \quad (\text{一个不依赖 } t \text{ 的常数}). \end{aligned}$$



可以用一张图来描述以上的模型：

HMM 广泛运用在交易择时，语音识别，基因测段等方面，据说 HMM 是美国著名对冲基金 文艺复兴科技公司的大奖章基金背后的模型。

② - HMM 定义与经典问题。 → 马尔可夫链 (Markov chain).

设 $\{I_t | t \in \mathbb{N}^+\}$ 是一离散时间的马尔可夫过程， $I_t \in I$ (状态空间)。
且 $|I| = n < +\infty$ 。该马尔可夫过程的转移矩阵为 A ，i.e.

$$A_{ij} = P(I_t = j | I_{t-1} = i), \quad \forall i, j \in I.$$

且初始分布为 π 。i.e.

$$\pi_i = P(I_1 = i) \quad \forall i \in I.$$

由随机过程的知识知 (A, π) 完全决定了 $\{I_t | t \in \mathbb{N}^+\}$ 。

此外在每一个时刻 t 下，状态 I_t 会发射 (emit) 一个观测 (observation) O_t 。

设 $O_t \in O$ (观测空间)，且有发射矩阵 B ，i.e.

$$|O| = m.$$

$$B_{io} = P(O_t = o | I_t = i)$$

其中 $\{O_t | t \in \mathbb{N}^+\}$ 观测序列可见，而 $\{I_t | t \in \mathbb{N}^+\}$ 是 Hidden 的。

令 $\lambda = (A, B, \pi)$ ，则 λ 完全决定一个 HMM。

HMM 有以下三个重要问题：

一 给定 $\lambda = (A, B, \pi)$ ，给定观测序列 $O_T = (O_1, O_2, \dots, O_T)$ ，计算
这一观测的可能性。i.e. $P(O_T | \lambda)$ 。 (用 Forward 算法求解)。

一 给定 $\lambda = (A, B, \pi)$ ，给定观测序列 $O_T = (O_1, \dots, O_T)$ 计算
最可能导致这种观测的状态链 I_T^* 。i.e. $I_T^* = \arg\max_I P(I | \lambda, O_T)$ 。
(用 Viterbi 算法)。

一 给定 $O_T = (O_1, O_2, \dots, O_T)$ ，给定 $|I| = n$ ， $|O| = m$ ，找最可能的
系统参数 $\lambda = (A, B, \pi)$ 。i.e. $\lambda^* = \arg\max_{\lambda} P(O | \lambda)$ 。
(用 Baum-welch 算法)。

③- Forward 算法.

给定 $\lambda = (A, B, \pi)$ 给定 $O_T = (o_1, \dots, o_T)$.

令 $\alpha_t(i) = P(o_1, o_2, \dots, o_t, i_t = q_i | \lambda)$ (称为前向根概率)

由全根概率公式 $P(O_T | \lambda) = \sum_{i_T \in I} P(O_T, i_T = i | \lambda)$

$$\cancel{\sum_{i_T \in I} P(O_T, i_T = i | \lambda)} = \sum_{i_T \in I} \alpha_T(i)$$

且注意到 $\alpha_{t+1}(i) = P(o_1, o_2, \dots, o_{t+1}, i_{t+1} = i | \lambda)$

$$= P(o_{t+1} | o_1, o_2, \dots, o_t, i_{t+1} = i, \lambda) \times P(o_1, \dots, o_t, i_{t+1} = i | \lambda)$$

$$(\text{发射关联假设}) = b_{i, o_{t+1}} \times P(o_1, \dots, o_t, i_{t+1} = i | \lambda)$$

$$(\text{全根瓦}) = b_{i, o_{t+1}} \times \sum_{j=1}^N P(o_1, \dots, o_t, i_t = j, i_{t+1} = i | \lambda)$$

$$= b_{i, o_{t+1}} \sum_{j=1}^N P(i_{t+1} = i | i_t = j, o_1, \dots, o_t, \lambda) \times P(i_t = j, o_1, \dots, o_t | \lambda)$$

$$(\text{马氏性}) = \underline{b_{i, o_{t+1}} \sum_{j=1}^N a_{ji} \alpha_t(j)}$$

故我们可以一层一层, 从下往上, 递推计算 α 矩阵 $= [\alpha_t(i)]_{T \times N}$.

$$\text{其中第一行 } \alpha_1(i) = P(o_1, i_1 = i | \lambda)$$

$$= P(o_1 | i_1 = i, \lambda) \times P(i_1 = i | \lambda)$$

$$= b_{i, o_1} \times \pi_i.$$

这便是 Forward 算法. 比传统的计算方法快很多.

④- Viterbi 算法

给定 $\lambda = (A, B, \pi)$ 给定 $O_T = (o_1, \dots, o_T)$.

$$\text{定义 } \delta_t(i) = \max_{(i_1, \dots, i_{t-1})} p(o_1 \dots o_t, i_t = i, (i_1 \dots i_{t-1}) \mid \lambda).$$

$$\begin{aligned} \text{显然有 } \max_I p(I \mid O_T, \lambda) &= \max_I \frac{p(I, O_T \mid \lambda)}{p(O_T \mid \lambda)} \\ &= \frac{\max_I p(I, O_T \mid \lambda)}{p(O_T \mid \lambda)} = \frac{\max_{j \in I} \delta_T(j)}{p(O_T \mid \lambda)} \quad (\text{动态规划}) \end{aligned}$$

$$\begin{aligned} \text{而 } \delta_{t+1}(i) &= \max_{(i_1, \dots, i_t)} p(o_1 \dots o_{t+1} \text{ 且 } i_{t+1} = i \text{ 且 } (i_1 \dots i_t) \mid \lambda) \\ &= \max_{(i_1, \dots, i_t)} b_{i o_{t+1}} \times p(o_1 \dots o_t, i_{t+1} = i, (i_1 \dots i_t) \mid \lambda) \\ &= \max_{(i_1, \dots, i_t)} b_{i o_{t+1}} \times a_{i_t i} p(o_1 \dots o_t, (i_1 \dots i_t) \mid \lambda). \end{aligned}$$

$$(\text{动态规划}) = \max_j \left(\max_{(i_1, \dots, i_t)} a_{j i_t} \times b_{i o_{t+1}} p(o_1 \dots o_t, (i_1 \dots i_t) \mid \lambda) \right)$$

$$\cancel{\max_{j \in I}} = \max_j b_{i o_{t+1}} a_{j i_t} \delta_t(j)$$

故我们可以递推地计算最大似然状态列。

⑦ - Baum-welch 算法.

We want to maximize the log-likelihood function

$l(\lambda) = \log p(o | \lambda)$. By EM Algorithm, we can

maximize over $Q(\lambda, \bar{\lambda}) = \sum_I p(o, I | \bar{\lambda}) \times \log p(o, I | \lambda)$

while $p(o, I | \lambda) = \pi_{i_1} b_{i_1 o_1} a_{i_1 i_2} b_{i_2 o_2} \cdots a_{i_T i_T} b_{i_T o_T}$.

E Step:

$$\Rightarrow Q(\lambda, \bar{\lambda}) = \sum_I \log \pi_{i_1} p(o, I | \bar{\lambda}) + \sum_I \left(\sum_{t=1}^T \log a_{i_t i_{t+1}} \right) p(o, I | \bar{\lambda}) \\ + \sum_I \left(\sum_{t=1}^T \log b_{i_t o_t} \right) p(o, \lambda, I | \bar{\lambda})$$

M step:

Use Lagrange multiplier and set partial derivative to zero.

Details in P182 of '统计学习方法'.

